📖YOLOV1速览

1️⃣知识前导

RCNN（两阶段）

1.生成候选区域（Region Proposals）

Selective Search 方法：

- 先对输入图像进行 **多尺度分割**，生成一系列超像素（Superpixels）。
- 逐步合并相似的区域，形成不同大小的候选框（Region Proposals）。
- 最终生成 **大约 2000 个候选区域**，这些区域被认为可能包含目标。

2.特征提取（Feature Extraction）

使用 AlexNet对每个候选区域进行特征提取：

- **将每个候选区域缩放到固定大小**（如 224×224）。
- **送入 CNN 提取特征**（通常使用预训练的 CNN，如 AlexNet、VGG16）。
- **得到特征向量**，并存入 SVM 进行分类

3. 分类与回归

RCNN 采用 **两个独立的模型** 来进行目标分类和边界框修正：

- 目标分类（Classification）
  - 采用 **SVM（支持向量机）** 对 CNN 提取的特征进行分类，判断该候选区域属于哪个类别（如 "cat", "dog", "car"）。
- 边界框回归（Bounding Box Regression）
  - 由于 Selective Search 生成的候选框可能不够准确，RCNN 训练了一个 **线性回归模型** 来调整边界框的位置，使其更贴合目标。

4. 进行目标检测

- 由于 多个候选区域可能覆盖同一个目标，会导致多个检测框。为了得到最终的检测结果，RCNN 采用：
  - 非极大值抑制（NMS, Non-Maximum Suppression）：
    - 按置信度排序，删除与高置信度目标重叠度高（IOU > 阈值）的框，保留最优框。
- 最终输出检测结果，包括：
  - **类别标签**
  - **目标位置（Bounding Box: x, y, w, h）**

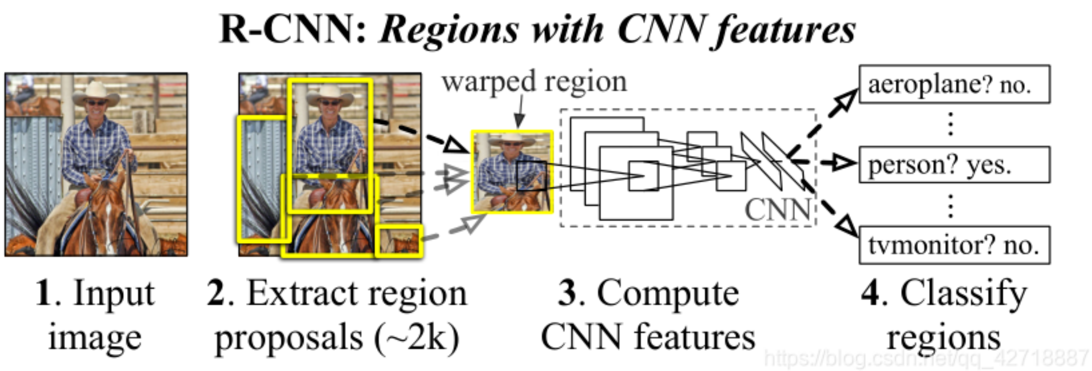

2️⃣YOLOv1（单阶段）

核心思想：

1、**把目标检测视为一个单一的回归问题**，即从输入图像直接预测目标的类别和位置，而不是像 RCNN 那样先生成候选区域再分类。

2、**整张图像只通过一次 CNN 前向传播**，直接得到所有目标的类别和边界框，因此速度极快，适用于**实时检测**。（端到端）

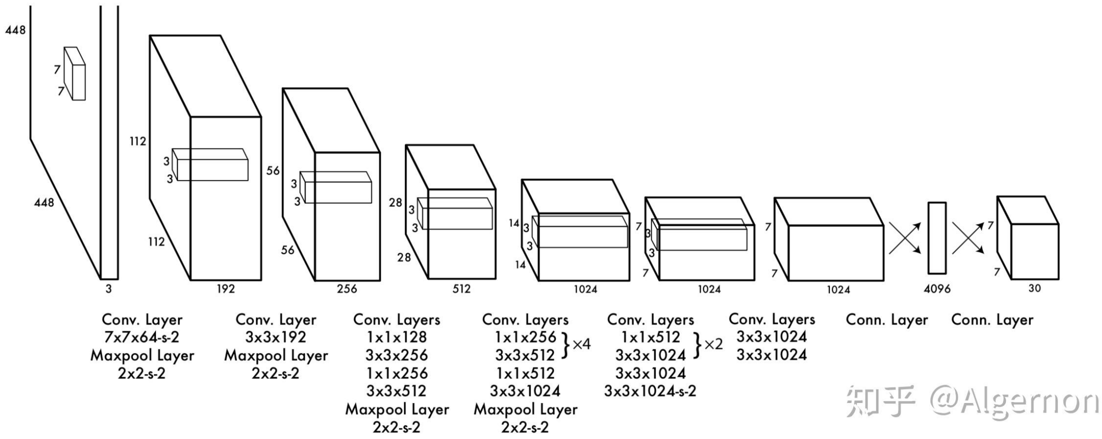

算法流程

预测阶段：

1. 将输入图像划分为网格

- 将图像缩放到固定尺寸（448x448）
- 把输入图像划分成 **S × S 的网格**（比如 7×7）。
- 每个网格的作用：
  - 如果一个物体的中心落在某个网格中，这个网格就负责检测这个目标。

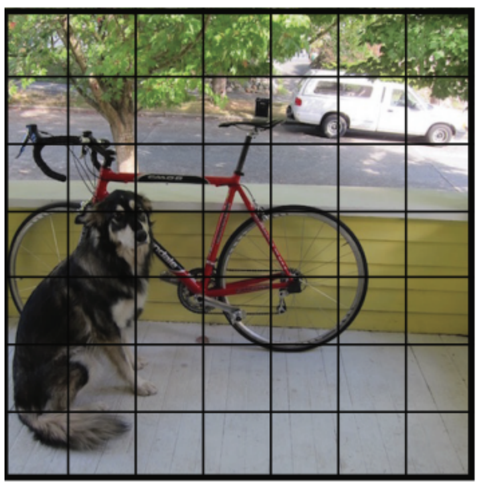

S × S grid on input

2.前向传播

（1）每个网格预测多个边界框

- 每个网格（Cell）预测 B 个边界框（Bounding Boxes）和对应的置信度（Confidence Score）：
  - 边界框信息：(x, y, w, h)
    - (x,y)(x, y)(x,y) 表示目标中心相对于该网格的位置（归一化到 0~1）。
    - (w,h)(w, h)(w,h) 是目标相对于整张图像的宽高（归一化到 0~1）。
  - **置信度（Confidence）**：表示边界框内是否有物体。

（2）每个网格同时预测类别（Class Prediction）

- **每个网格还会预测 C 个类别的概率。**
- 但注意，类别的概率是**条件概率**，表示**在该网格有物体的前提下，该物体属于某个类别的概率。**

最终输出形状：[redacted]对于YOLOv1输出7x7x30

S*S((B*5)+C)

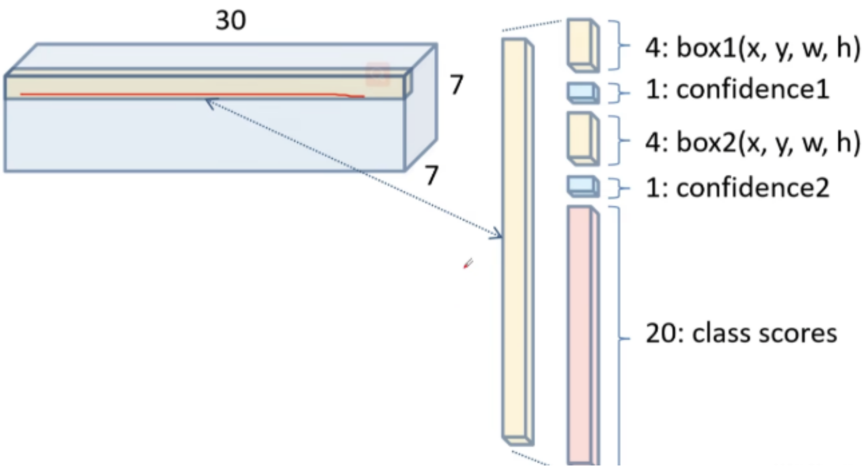

3.后处理

(1) 计算边界框的实际坐标

$$x_r = (x_p + c_x) * \text{grid\_size} \tag{1}$$

$$y_r = (y_p + c_y) * \text{grid\_size} \tag{2}$$

$$w_r = w_r * \text{img\_width} \tag{3}$$

$$h_r = h_p * \text{img\_height} \tag{4}$$

(2)计算最终的置信度分数

YOLO 计算每个边界框的 **置信度分数**（Confidence Score）：

$$\text{Confidence} = P(\text{Object}) \times \text{IOU}_{\text{pred, truth}} \tag{5}$$

- **P(Object)**：网格是否包含目标的概率。
- **IOU（Intersection over Union）**：预测的边界框与真实目标的重叠程度。

$$IOU = \frac{\text{Area}_{\text{intersection}}}{\text{Area}_{\text{union}}} \tag{6}$$

置信度过低的框会被丢弃（通常设定阈值，比如 **0.25**）。

(3) 非极大值抑制（Non-Maximum Suppression, NMS）

由于 YOLO 可能对同一个目标预测多个边界框，需要去重：

1. **按置信度排序**：优先保留置信度高的框。
2. **计算 IOU（交并比）**
3. **删除高 IOU（>0.5）的重复框**，只保留最优的目标框。

后处理可视化

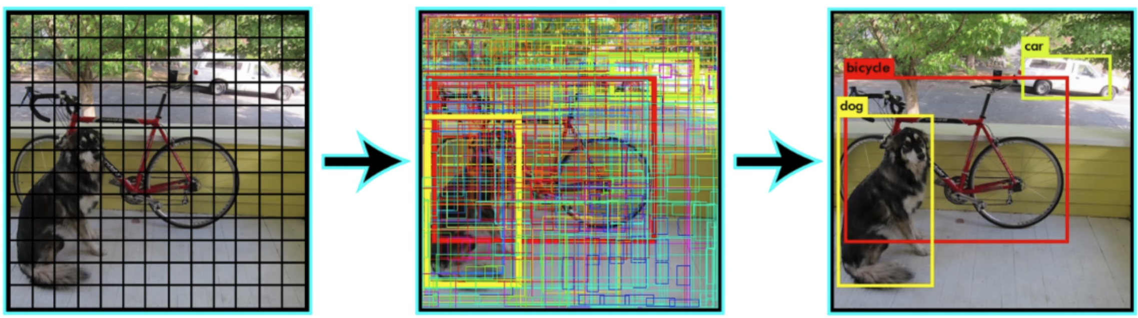

NMS详解

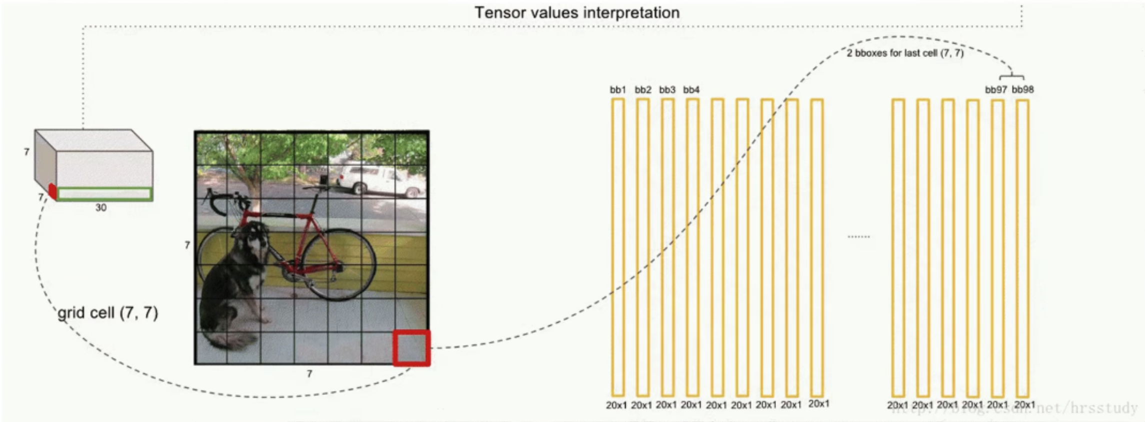

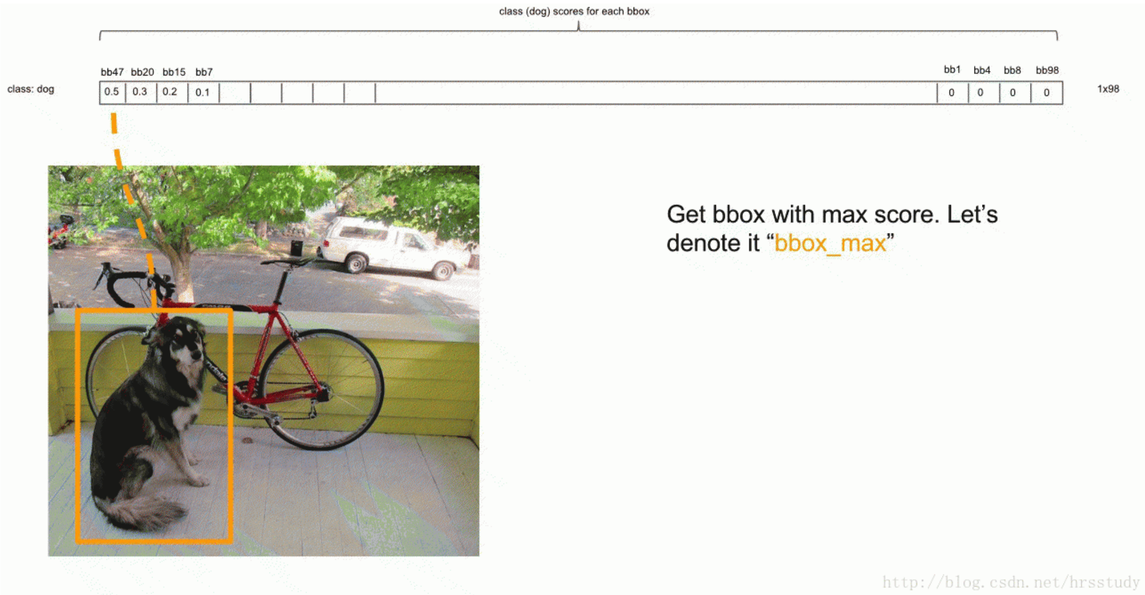

训练阶段

（1）数据预处理

- 图像归一化
- 划分网格
- 生成标签格式

（2）前向传播

- 通过 **CNN 提取特征** 并预测目标信息。

（3）计算损失

$\mathbb{1}_{ij}^{\text{obj}}$ 该预测框是否负责监测，是为1不是为0

$\mathbb{1}_{ij}^{\text{noobj}}$ 若网格没有目标为0，否则为1

- 位置损失（Localization Loss）

5

$$\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \tag{7}$$

(x_i, y_i)：预测框的中心坐标

$(\hat{x}_i, \hat{y}_i)$：真实框的中心坐标

- 尺度损失（Scale Loss）

5

$$\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2 \right] \tag{8}$$

w_i, h_i：预测框宽高

$\hat{w}_i, \hat{h}_i$：真实框宽高

- 目标置信度损失（Confidence Loss for Objects）

$$\sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \tag{9}$$

C_i：预测置信度　$\hat{C}_i$：真实置信度

- 背景置信度损失（Confidence Loss for No Object）

0.5

$$\lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \tag{10}$$

- 分类损失（Classification Loss）

$$\sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \tag{11}$$

预测类别 真实类别

- 最终损失函数（YOLO Loss）

$$\mathcal{L} = \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2\right] + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2\right] + \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 + \lambda_{\text{noobj}} \sum$$